

MANUEL DU SANDBOX AI FINOPS & GUIDE PORTFOLIO

Entraînement Pas-à-Pas, Résilience aux Pannes LLM & Valorisation Professionnelle pour AI Test Architect

Pourquoi ce Sandbox a été créé ? En banque de détail et de financement, recruter un QA sur l'IA exige bien plus que des connaissances théoriques : vous devez prouver que vous savez **mesurer le coût unitaire au centième de centime d'euro, détecter les pannes financières silencieuses et bloquer les attaques par déni de portefeuille**. Ce sandbox bancaire autonome fonctionne à **coût 0€** (aucune clé API payante requise, simulation mathématique haute fidélité) et constitue une **vitrine d'ingénierie prête à publier sur votre profil GitHub**.

Pilier du Sandbox	Rôle Opérationnel dans la Simulation	Valeur Ajoutée Portfolio
1. Moteur Haute Fidélité	Simule Llama-3-70B (vLLM local), GPT-4o et Claude 3.5 Sonnet avec calculs stochastiques de tokens et détection réelle du Prompt Caching (préfixes >= 1024 tokens).	Démontre une compréhension intime de l'arithmétique des tokens et de l'architecture d'inférence.
2. Laboratoire de Chaos	Injecte 4 défaillances réelles : destruction de cache, bascule silencieuse Sovereign vers Cloud, attaque Denial of Wallet, boucle d'agent autonome.	Prouve votre capacité à concevoir des disjoncteurs financiers et des tests de résilience.
3. Outils de Restitution	Tableau de bord interactif HTML5 (Chart.js), télémétrie console, suite de tests Pytest (5 tests) et générateur d'étude de cas GitHub PORTFOLIO_CASE_STUDY.md.	Fournit un livrable visuel et professionnel immédiatement démontrable en entretien.

Architecture du Flux d'Inférence & Dispositifs de Contrôle QA



RÉPERTOIRE AUTONOME PRET A L'EMPLOI

L'ensemble du projet est regroupé dans le dossier **bankai_finops_sandbox/**. Vous pouvez cloner ou copier directement ce répertoire sur votre compte GitHub personnel sans aucune modification.

2. Les 3 Cas d'Usage Métier Bancaires du Sandbox

Le module engine/workloads.py modélise 3 cas réels de banques tier-1, chacun soumis à des règles réglementaires strictes et à des contraintes de coût spécifiques :

Cas n°1 : Octroi de Crédit Retail & Scoring (Bâle IV / ACPR / EBA)

- **Contexte métier** : Système classifié **Haut Risque (Annexe III EU AI Act)**. Évalue la solvabilité des emprunteurs particuliers, calcule le taux d'effort (DTI max 35.00%) et la probabilité de défaut (PD).
- **Spécificité FinOps** : Le prompt système contient plus de **2 500 tokens** de règles réglementaires immuables. Si le Prompt Caching est maintenu, le préfixe bénéficie d'une décote de 50% à 90% sur le coût d'entrée. Coût nominal par dossier : **< 0.0004 €**.
- **Risque QA** : Toute modification accidentelle du début du prompt détruit le cache pour 100% des requêtes suivantes.

Cas n°2 : Extraction Documentaire KYC & UBO (5e Directive AML / LCB-FT)

- **Contexte métier** : Contrôle automatisé des liasses fiscales, bilans comptables et extraits Kbis d'entreprises clientes. Extraction des Bénéficiaires Effectifs (UBO > 25%) et détection de Personnes Politiquement Exposées (PPE).
- **Spécificité FinOps** : La taille des fichiers entrants est imprévisible (de 2 pages à 500 pages de bilans scannés).
- **Dispositif QA Anti-DoW** : Un validateur pré-modèle inspecte le nombre de pages et le volume d'octets. Si le fichier excède 10 pages ou 50 Ko, il est rejeté ou routé vers un OCR sélectif, **évitant 100% de la dépense LLM (0 € dépensé)**.

Cas n°3 : Copilote de Banque Privée & Gestion de Patrimoine (MiFID II)

- **Contexte métier** : Assistant virtuel pour les banquiers privés structurant des portefeuilles pour clients fortunés (HNWI). Chaque interaction accumule l'historique de la conversation.
- **Spécificité FinOps** : Sans garde-fou, un échange de 10 tours passe de 1 000 tokens au tour 1 à plus de 12 000 tokens au tour 10 (inflation quadratique des coûts).
- **Dispositif QA Fenêtre Glissante** : Le framework tronque et résume les échanges antérieurs pour ne conserver que le prompt système et les 2 derniers tours, maintenant le coût unitaire stable et prévisible.

Cas d'Usage Bancaire	Modèle Inférence	Tokens / Requête	Plafond NFR FinOps	Garde-Fou QA Opéré
Octroi Crédit Retail	Llama-3-70B / GPT-4o-mini	2 800 tokens (80% cached)	CPIT < 0.0005 €	Assertion Cache Hit Ratio > 75%
Extraction KYC / UBO	GPT-4o / Vision OCR	5 000 à 45 000 tokens	Rejet si doc > 10 pages	Pre-Execution Anti-DoW Filter
Copilote Patrimoine	Claude 3.5 / GPT-4o-mini	1 500 tokens constants	Coût session < 0.01 €	Sliding Context Window (k=2)

3. Le Laboratoire de Chaos Financier & d'Anomalies

Dans le module chaos/chaos_injector.py, vous pouvez injecter 4 défaillances réelles. En entretien, ce sont ces scénarios qui démontrent votre valeur : vous montrez non seulement comment la panne se produit, mais aussi l'économie chiffrée exacte générée par vos garde-fous QA.

Anomalie Financière	Mécanisme de Défaillance Sans Protection	Protection QA Automatisée	Gain Constaté
1. Cache-Busting (Destruction Cache)	Un développeur concatène un identifiant dynamique ou un horodatage au début du prompt système. Le provider considère chaque appel comme un prompt nouveau : le cache tombe à 0%, la facture triplée.	Test de non-régression Pytest vérifiant le cache_hit_ratio et forçant le placement des variables dynamiques en queue de prompt.	+34.4% d'économies
2. Silent Fallback (Bascule Non Contrôlée)	Le cluster local souverain vLLM subit un Out Of Memory (OOM). L'application bascule silencieusement vers GPT-4o Cloud. Sans alerte, 10 000 requêtes/heure fuient vers une API externe payante (infraction DORA).	FallbackCircuitGuard sur fenêtre glissante : coupe la bascule après 10 requêtes et passe en mode dégradé (moteur de règles à 0€).	+73.4% d'économies
3. Denial of Wallet (Bombardement KYC)	Un utilisateur ou un robot pousse des dossiers de 50 pages de bilans financiers consolidés (350 Ko). L'IA facture chaque page au tarif LLM/Vision le plus cher.	Validation pré-modèle rejetant 100% des fichiers volumineux avant tout appel d'inférence, avec journalisation d'une alerte sécurité.	+100.0% (0€ dépensé)
4. Runaway Loop (Boucle Folle d'Agent)	Un agent autonome d'investigation tourne en boucle (40 itérations) en cherchant récursivement des filiales sans jamais atteindre sa condition d'arrêt.	MaxStepBudgetGuard qui interrompt matériellement l'exécution au 5ème tour et escalade vers un réviseur humain.	+87.5% d'économies

Bilan Chiffré Consolidé de la Simulation de Chaos

Indicateur Financier Global	Sans Garde-Fou (Naïf)	Avec Framework QA FinOps	Gain Net Réalisé
Dépense d'inférence brute	4.5572 €	0.1607 €	+4.3965 € (96.5%)
Extrapolation mensuelle (100k req)	4 557,20 € / mois	160,70 € / mois	+4 396,50 € / mois
Statut de conformité DORA / AI Act	REJETÉ (Non conforme)	HOMOLOGUÉ POUR LE CAB	Score Audit : 100/100 (Grade A)

L'ARGUMENT CHOC POUR VOS ENTRETIENS

« Sur un simple échantillon de tests, l'implémentation de 4 garde-fous a permis de réduire les coûts de 96.5%. À l'échelle des 500 000 dossiers mensuels de la banque, cela représente plus de 21 000 € d'économies récurrentes chaque mois. »

4. Guide d'Exécution Pas-à-Pas & Outils Visuels

Le sandbox est entièrement contrôlable depuis le terminal VS Code via le script universel `sandbox.ps1`. Voici comment exécuter chaque composant et ce qui s'affiche à l'écran :

Action 1 : Exécuter la Simulation et Injecter le Chaos

COMMANDE EXPRESS 1 CLIC

Dans le terminal de VS Code, tapez :

`.lsandbox.ps1 run`

(Ou directement : `python run_sandbox.py --mode all`)

Ce qui se passe : Le script simule 40 décisions de crédit, 15 extractions KYC et 6 tours de gestion de patrimoine, calcule les métriques en direct, injecte les 4 pannes de chaos, génère le dashboard HTML et met à jour le fichier `PORTFOLIO_CASE_STUDY.md`.

Action 2 : Ouvrir le Tableau de Bord Visuel Interactif

OUVERTURE DU DASHBOARD WEB

Tapez : **`.lsandbox.ps1 html`**

Votre navigateur s'ouvre instantanément sur le fichier `bankai_finops_dashboard.html`.

Ce que vous voyez à l'écran :

- **Cartes KPI en tête :** Économies nettes (+4.40 €), taux de cache préfixe (70.2%), coût unitaire moyen (0.00077 €).
- **Graphique en barres `Chart.js` :** Comparatif visuel direct 'Sans Garde (Rouge)' vs 'Protégé QA (Vert)'.
- **Diagramme Donut :** Répartition des gains financiers par scénario de défaillance.
- **Matrice d'Audit détaillée :** Liste des remédiations techniques implémentées par le QA Architect.

Action 3 : Valider les Disjoncteurs via la Suite Pytest

VALIDATION DES TESTS AUTOMATISÉS

Tapez : **`.lsandbox.ps1 test`**

Résultat : **5 passed in 0.16s**. Tous les disjoncteurs et plafonds de budget sont validés.

Ce que testent les 5 fonctions automatisées :

1. `test_credit_scoring_nominal_budget` : Assertion sur le coût unitaire (< 0.0005 €) et activation du cache.
2. `test_cache_busting_anomaly_mitigation` : Vérifie que le maintien du cache réduit la facture d'au moins 30%.
3. `test_silent_fallback_circuit_breaker` : Vérifie le déclenchement du disjoncteur lors d'une bascule Cloud.
4. `test_denial_of_wallet_guard_blocks_heavy_docs` : Vérifie le rejet des documents volumineux à 0€.
5. `test_wealth_copilot_sliding_window_inflation` : Vérifie la maîtrise de la facture sur sessions longues.

5. Valorisation Portfolio, GitHub & Réussite en Entretien

Ce projet a été conçu pour être votre **atout maître en entretien d'embauche**. Voici la feuille de route pour le publier et le présenter avec la posture d'un AI Test Architect chevronné :

1. Comment Publier ce Projet sur votre GitHub

- **Nom du dépôt** : bankai-finops-sandbox
- **Description GitHub** : *'High-fidelity banking AI FinOps & resilience lab. Simulates LLM cost drift, prompt caching, denial of wallet attacks, and circuit breakers for regulated tier-1 banks (EU AI Act & DORA compliant).'*
- **Topics recommandés** : ai-finops, qa-architecture, llm-resilience, banking-ai, dora-compliance, pytest.
- **Fichier phare** : Épinglez le fichier PORTFOLIO_CASE_STUDY.md généré automatiquement, qui détaille les métriques et les schémas d'architecture.

2. Comment le Formuler sur votre CV & LinkedIn

BLOC CV RECOMMANDÉ (PROJET PHARE)

AI Test Architect & FinOps Lead — Apex Bank AI FinOps Framework

- Conception d'un framework de recette financière continue pour modèles LLM bancaires (Bâle IV, DORA Art. 28).
- Réduction de 96.5% des coûts d'inférence en situation de chaos grâce au Prompt Caching et aux disjoncteurs financiers.
- Mise en place de filtres pré-modèle anti-Denial of Wallet et de Quality Gates bloquantes en CI/CD (Score Audit 100/100).

3. Le Script de Pitch en Entretien (Méthode STAR en 4 Temps)

Étape STAR	Ce que vous dites mot pour mot au recruteur ou au Lead FinOps
Situation	« Chez Apex Bank, les squads déployaient des modèles LLM sans visibilité sur le coût par transaction ni sur le risque de dérive budgétaire en cas de panne de cluster souverain. »
Tâche (Rôle QA)	« En tant qu'AI Test Architect, ma mission était de définir les critères d'acceptation financiers (NFRs), d'instrumenter les disjoncteurs de secours et de valider l'homologation pour le CAB. »
Action	« J'ai conçu un bac à sable de tests simulant 3 cas bancaires réels (crédit, KYC, patrimoine) et injectant 4 pannes de chaos (destruction de cache, fuite Cloud, attaque DoW, boucles folles d'agents). »
Résultat Chiffré	« Mes tests ont prouvé une économie de 96.5% sur les scénarios critiques, plafonné le coût unitaire sous 0.0005 € et garanti la conformité stricte DORA Art. 28 avant la mise en production. »

6. Fiche de Survie, Formules Clés & Checklist d'Entraînement

Gardez cette page sous les yeux lors de vos sessions d'entraînement personnel et avant vos entretiens d'embauche :

Tableau Récapitulatif des Commandes du Sandbox

Commande PowerShell	Action Opérationnelle Exécutée	Fichiers Modifiés / Produits
.\sandbox.ps1 run	Exécute les flux nominaux + les 4 pannes de chaos, calcule la rentabilité et génère tous les rapports.	Console + bankai_finops_dashboard.html + PORTFOLIO_CASE_STUDY.md
.\sandbox.ps1 test	Lance la suite de 5 tests automatisés Pytest vérifiant les disjoncteurs et les plafonds NFR.	Rapport de test Pytest standard (5 passed en ~0.16s)
.\sandbox.ps1 html	Ouvre le tableau de bord visuel interactif Chart.js directement dans votre navigateur web par défaut.	Visualisation du fichier bankai_finops_dashboard.html
.\sandbox.ps1 portfolio	Régénère l'étude de cas Markdown prête pour GitHub avec les derniers résultats d'exécution.	Mise à jour de PORTFOLIO_CASE_STUDY.md

Les 2 Formules Mathématiques Clés à Retenir

1. Coût par Transaction (CPIT)	$CPIT = (Tokens_in_uncached * P_in + Tokens_in_cached * P_cached + Tokens_out * P_out) / 10^6$
2. Seuil de Rentabilité GPU (Break-Even)	$Seuil_Mensuel = CapEx_Amorti_Mensuel / (CPIT_Cloud_Public - CPIT_Souverain_Local)$

Checklist d'Entraînement en 6 Étapes Pratiques

- [] **Étape 1** : Ouvrez le terminal VS Code dans bankai_finops_sandbox/ et tapez .\sandbox.ps1 run.
- [] **Étape 2** : Ouvrez le dashboard avec .\sandbox.ps1 html et explorez les 2 graphiques interactifs.
- [] **Étape 3** : Lancez .\sandbox.ps1 test pour vérifier le passage au vert des 5 assertions financières.
- [] **Étape 4** : Lisez le fichier PORTFOLIO_CASE_STUDY.md généré pour vous imprégner du vocabulaire bancaire.
- [] **Étape 5** : Entraînez-vous à réciter le Pitch STAR (page 5) à voix haute en 60 secondes chrono.
- [] **Étape 6** : Poussez le dossier sur votre compte GitHub sous le nom bankai-finops-sandbox.

VOUS ÊTES 100% ARMÉ POUR VOTRE PROCHAIN RÔLE BANCAIRE

Grâce à ce bac à sable, vous n'êtes plus un candidat théorique : vous êtes un **AI Test Architect opérationnel** capable de protéger les budgets de la banque et de challenger un Lead FinOps dès votre premier jour en squad !